TEKNOLOGI REKAYASA KOMPUTER (TRK) • ANALISIS DATA UNTUK IOT

Paradigma Machine Learning untuk IoT, Time-Series Forecasting, & Deteksi Anomali

Materi Kuliah Pekan 9 (Pertemuan Pertama Pasca-UTS) | Alokasi Waktu: 2 x 50 Menit + Kick-Off Proyek Akhir

Dosen Pengampu: Mohammad Riza Nurtam, M.Kom & Ega Evinda Putri

Jurusan Rekayasa Pertanian dan Komputer — Politeknik Pertanian Negeri Payakumbuh (Semester 5)

Reload Pekan 1–7: Dari Data Bersih Menuju Kecerdasan Prediktif

Jembatan Konseptual: Menghubungkan Pra-Pemrosesan Statistik Menuju Machine Learning IoT

KILAS BALIK PARUH PERTAMA (PEKAN 1 - 7)

- **Akuisisi & Arsitektur (Pekan 1-2):** Mengalirkan telemetri sensor via protokol MQTT/AMQP pada hierarki komputasi Edge, Fog, dan Cloud.
- **Eksplorasi & Dekomposisi (Pekan 3-4):** Membedah komponen Trend, Seasonality, dan Noise serta mengukur korelasi Pearson (r) antar-sensor.
- **Pra-pemrosesan & Cleaning (Pekan 5-6):** Menambal nilai kosong (MCAR, MAR, MNAR) dengan interpolasi, menghaluskan noise (SMA/EMA), dan membuang outlier (Z-Score & IQR).
- **Komputasi Hemat Memori (Pekan 7):** Memproses aliran data di perangkat terbatas menggunakan Circular Buffer (deque) dan TinyML.

MENGAPA KITA BUTUH MACHINE LEARNING HARI INI?

➔ **Batasan Statistik Klasik:** Metode Z-Score, IQR, dan Moving Average hanya mengevaluasi apa yang SUDAH terjadi (deskriptif) dan memeriksa tiap sensor secara terpisah (univariat).

➔ **Kebutuhan Peramalan (Forecasting):** Petani tidak cukup tahu tanaman layu hari ini; petani butuh meramal berapa kelembaban tanah 6 JAM KE DEPAN sebelum tanaman stres air.

➔ **Deteksi Anomali Multivariat:** Bagaimana menangkap bahaya ketika 10 sensor terlihat normal secara individu, tetapi interaksi gabungannya melanggar pola normal?

➔ **Misi Pekan 9:** Memanfaatkan data yang telah bersih dari Pekan 1-7 untuk melatih model Machine Learning prediktif dan detektor anomali cerdas.

KATA KUNCI PEMBELAJARAN TERPADU: Berlaku hukum Garbage In, Garbage Out (GIGO): Model Machine Learning Pekan 9-10 hanya akan akurat apabila disuapi data yang telah melewati tahap pembersihan Pekan 5-6!

Rencana Pembelajaran Pekan 9 & Capaian Sub-CPMK (100 Menit)

Alur sistematis dari pergeseran paradigma pemrograman hingga peluncuran Proyek Akhir (Tugas Besar).

RUNDOWN SESI PERKULIAHAN (2 X 50 MENIT)

- **Sesi 1 (Menit 00 - 25):** Pergeseran Paradigma: Keterbatasan sistem pakar berbasis aturan (Rule-Based IF-ELSE) vs Machine Learning di pertanian presisi.
- **Sesi 2 (Menit 25 - 50):** Formulasi Masalah ML IoT (Regresi, Klasifikasi, Unsupervised) & konsep Lag Features pada Time-Series Forecasting.
- **Sesi 3 (Menit 50 - 80):** Aturan Train-Test Split (shuffle=False), metrik evaluasi (MAE, MSE, RMSE, R^2), dan cara kerja Isolation Forest.
- **Sesi 4 (Menit 80 - 100):** Diagnosa degradasi model (Sensor Drift vs Concept Drift) & Kick-Off Proyek Akhir (RTM Tugas Besar).

CAPAIAN PEMBELAJARAN KHUSUS (SUB-CPMK 9)

- **1. Analisis Paradigma:** Mampu menjelaskan alasan teknis mengapa aturan IF-ELSE kaku gagal menangani interaksi belasan variabel iklim mikro.
- **2. Problem Formulation:** Mampu memetakan studi kasus Smart Agriculture ke algoritma Regresi, Klasifikasi, atau Unsupervised Learning.
- **3. Metodologi Forecasting:** Menguasai konsep Autoregression (Lagging), pencegahan Data Leakage, dan perhitungan metrik galat prediksi.
- **4. Kick-Off Proyek Akhir:** Membentuk kelompok Tugas Besar dan merancang topik arsitektur pipeline analitik 5 lapis.

FOKUS KOMPETENSI ENGINEER: Seorang IoT Data Engineer tidak sekadar memanggil fungsi .fit() di Python, melainkan memahami formulasi matematis dan batasan fisik dari model yang dibangun.

Mengapa Aturan IF-ELSE Tradisional Runtuh di Pertanian Presisi?

Menganalisis kegagalan logika kondisional terprogram (Hard-Coded Rules) pada lingkungan terbuka.

CARA KERJA SISTEM PAKAR / RULE-BASED (IF-ELSE)

- **Aturan Diketik Eksplisit oleh Manusia:** Programmer menetapkan batas ambang manual di dalam kode: IF suhu > 32.0 AND tanah < 40.0 THEN nyalakan_pompa().
- **Kapan IF-ELSE Masih Efektif?:** Sangat baik untuk kendali pengaman tunggal sederhana (misal: matikan katup jika tekanan pipa > 8 bar di Edge).
- **Asumsi Lingkungan Statis:** Menganggap hubungan antar-variabel bersifat linier sederhana dan batas ambang tidak pernah berubah sepanjang musim.

TIGA PENYEBAB RUNTUHNYA IF-ELSE DI LAPANGAN

- **1. Ledakan Kombinasi (Curse of Dimensionality):** Laju layu tanaman ditentukan oleh interaksi non-linier 12+ variabel (suhu, RH, angin, radiasi PAR, pH, EC, umur tanaman). Mustahil menulis ribuan cabang IF-ELSE secara manual!
- **2. Ambang Batas yang Bergeser Dinamis:** Kelembaban tanah 40% aman bagi bibit cabai saat cuaca mendung, namun mematikan bagi tanaman fase berbuah di siang hari berangin kencang.
- **3. Pola Tersembunyi Frekuensi Tinggi:** Manusia tidak mampu merumuskan aturan IF-ELSE dari 10.000 angka getaran/detik untuk memprediksi kapan bearing traktor akan patah.

KESIMPULAN ARSITEKTURAL: Ketika jumlah sensor banyak dan interaksinya kompleks/non-linier, manusia harus berhenti menebak rumus IF-ELSE secara manual dan membiarkan algoritma Machine Learning menemukannya dari data!

Pergeseran Paradigma: Pemrograman Tradisional vs Machine Learning

Memahami pembalikan alur kerja antara fase pelatihan (Training) dan fase prediksi (Inference).

1. PEMROGRAMAN TRADISIONAL (DETERMINISTIK)

- **Input ke Komputer:** Data Sensor Saat Ini (X) + Aturan Logika (Rules / IF-ELSE) yang diketik oleh programmer.
- **Proses Eksekusi CPU:** Mengevaluasi percabangan logika secara kaku tanpa proses belajar.
- **Output yang Dihasilkan:** Jawaban / Tindakan Aktuator (y).
- **Keterbatasan Utama:** Sistem tidak memiliki kemampuan adaptasi; meskipun telah merekam data selama 5 tahun, kinerjanya tetap sama seperti hari pertama.

2. PARADIGMA MACHINE LEARNING (DATA-DRIVEN)

➔ **Fase 1 — Training (Proses Belajar di Cloud/Server):** Input berupa Data Historis Sensor (X) + Catatan Hasil Nyata Masa Lalu (Label y) ➔ Algoritma menghasilkan MODEL MATEMATIS f(X).

➔ **Fase 2 — Inference (Prediksi Real-Time):** Input berupa Data Sensor Baru (X') dimasukkan ke dalam Model Terlatih f(X) ➔ Menghasilkan PREDIKSI / KEPUTUSAN BARU (ŷ).

➔ **Apa itu 'Model' Sebenarnya?:** Bukan kotak hitam magis, melainkan persamaan matematika beserta bobot parameter (weights) yang telah dioptimasi oleh data.

INTISARI PARADIGMA ML: Pemrograman Tradisional: [Data + Aturan ➔ Jawaban]. | Machine Learning Training: [Data Historis + Jawaban Nyata ➔ Aturan/Model].

Peta Taksonomi 3 Kategori Machine Learning pada Sistem IoT

Menentukan keluarga algoritma yang tepat berdasarkan sifat label historis dan bentuk target output.

Kategori Pembelajaran	Syarat Label Historis	Bentuk Output (ŷ)	Contoh Studi Kasus Smart Agriculture	Algoritma Populer
1. Supervised Regression (Forecasting)	Wajib Ada Label (Angka Kontinu)	Nilai Desimal Berkelanjutan (misal: 29.4°C, 62.5%)	Meramal suhu rumah kaca & kelembaban tanah 3 jam ke depan; estimasi sisa umur pompa (RUL).	Linear Regression, Random Forest Regressor, ARIMA, LSTM
2. Supervised Classification	Wajib Ada Label (Kategori Diskrit)	Kelas / Kategori Tegas (misal: Normal vs Rusak)	Mendiagnosis jenis penyakit daun dari citra; klasifikasi status getaran motor (Sehat, Kavitasi, Aus).	Logistic Regression, Decision Tree, SVM, Random Forest, CNN
3. Unsupervised Learning (Anomaly Detection)	TIDAK BUTUH LABEL (Unlabeled Data)	Skor / Label Anomali (+1 Normal, -1 Anomali)	Mendeteksi kombinasi ganjil suhu, kelembaban, dan pH tanah tanpa riwayat label kerusakan sebelumnya.	Isolation Forest, One-Class SVM, K-Means, Autoencoder

ATURAN CEPAT FORMULASI MASALAH: Ingin menebak BERAPA nilainya besok? Gunakan Regresi. Ingin menebak APA jenis kondisinya? Gunakan Klasifikasi. Tidak punya label kerusakan masa lalu? Gunakan Unsupervised Anomaly Detection!

Bagaimana Mesin Meramal Masa Depan? Konsep Lag Features

Mentransformasikan deret waktu tunggal menjadi matriks fitur Supervised Learning (Autoregression).

PRINSIP DASAR AUTOREGRESSION & LAGGING

- **Hukum Inersia Termal & Fisika:** Suhu atau kelembaban tanah pada pukul 11:00 (y_t) tidak muncul secara acak, melainkan kelanjutan dari suhu pukul 10:00 (y_{t-1}) dan pukul 09:00 (y_{t-2}).
- **Apa itu Lag Feature?:** Kolom fitur baru yang diciptakan dengan menggeser (shift) nilai historis sensor mundur sebanyak 1, 2, ..., p langkah waktu sebagai input X bagi model.
- **Rumus Regresi Linier Lag-2:** $\hat{y}_t = \beta_0 + (\beta_1 \times Suhu_{t-1}) + (\beta_2 \times Suhu_{t-2})$, di mana β adalah bobot yang dipelajari oleh Scikit-Learn.
- **Implementasi di Pandas:** Gunakan df['suhu_lag1'] = df['suhu'].shift(1) lalu bersihkan baris awal dengan df.dropna().

ILUSTRASI TRANSFORMASI TABEL (LAG-1 & LAG-2)

- **Pukul 08:00 (Baris Awal):** Suhu Aktual = 25.0°C | Lag-1 = NaN | Lag-2 = NaN ➔ (Dihapus oleh dropna karena belum punya masa lalu).
- **Pukul 09:00 (Baris Kedua):** Suhu Aktual = 26.2°C | Lag-1 = 25.0°C | Lag-2 = NaN ➔ (Dihapus oleh dropna).
- **Pukul 10:00 (Sampel Latih #1):** Target y = 27.8°C <== Diprediksi dari Fitur X: [Lag-1 = 26.2°C, Lag-2 = 25.0°C].
- **Pukul 11:00 (Sampel Latih #2):** Target y = 29.5°C <== Diprediksi dari Fitur X: [Lag-1 = 27.8°C, Lag-2 = 26.2°C].
- **Pukul 12:00 (Prediksi Masa Depan):** Target $\hat{y}$ = ??? °C <== Dihitung model dari [Lag-1 = 29.5°C, Lag-2 = 27.8°C]!

SYARAT MUTLAK PRA-PEMROSESAN: Sebelum membuat kolom .shift(1), pastikan indeks waktu sudah seragam (resampled) dan tidak ada lubang waktu yang terlompati!

Aturan Emas Pembagian Data Time-Series: shuffle=False!

Mencegah kesalahan fatal kebocoran masa depan (Data Leakage / Look-Ahead Bias) saat evaluasi model.

MENGAPA DATA WAJIB DIBAGI (80% TRAIN : 20% TEST)?

- **Bahaya Menguji dengan Soal Latihan:** Jika model diuji menggunakan data yang sama persis saat pelatihan, model hanya menghafal derau masa lalu (Overfitting) dan gagal saat menghadapi data baru.
- **Training Set (80% Periode Awal):** Disuapkan ke dalam fungsi model.fit(X_train, y_train) agar mesin mempelajari pola hubungan antar-variabel.
- **Testing Set (20% Periode Akhir):** Disembunyikan selama pelatihan, lalu dipakai pada model.predict(X_test) untuk menguji akurasi ramalan secara jujur.

MENGAPA DILARANG MENGACAK BARIS (SHUFFLE=TRUE)?

- **Perilaku Bawaan Scikit-Learn:** Fungsi train_test_split(X, y) secara default mengacak urutan baris (shuffle=True) karena dirancang untuk data tabel non-waktu.
- **Bencana Look-Ahead Bias di IoT:** Jika diacak, data masa depan (misal tanggal 28 Oktober) masuk ke Training Set untuk menebak suhu masa lalu (tanggal 10 Oktober). Akurasi terlihat tinggi palsu di lab, tapi hancur di produksi!
- **Sintaks Wajib Time-Series:** X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, shuffle=False).

HUKUM KRONOLOGIS TIME-SERIES: Urutan waktu adalah sakral: 80% data masa lalu (Misal: 1 s.d. 24 Oktober) WAJIB melatih model untuk diuji pada 20% data masa depan (25 s.d. 31 Oktober)!

Metrik Evaluasi Akurasi Forecasting: MAE, MSE, RMSE, & R^2

Empat tolok ukur matematis untuk menilai seberapa tepat tebakan model AI terhadap kenyataan sensor.

1. MAE & 2. MSE / RMSE (BERBASIS SELISIH GALAT)

- **MAE (Mean Absolute Error):** Rata-rata selisih mutlak |y_aktual - ŷ_prediksi|. Sangat intuitif karena satuannya sama persis dengan sensor (misal: rata-rata meleset 0.45°C).
- **MSE (Mean Squared Error):** Rata-rata dari kuadrat selisih galat: (y_aktual - ŷ_prediksi)^2. Memberikan bobot penalti kuadratik pada kesalahan besar.
- **RMSE (Root Mean Squared Error):** Akar kuadrat dari MSE (√MSE). Mengembalikan satuan ke °C, namun jauh lebih sensitif menghukum lonjakan tebakan yang meleset jauh dibandingkan MAE!

3. R-SQUARED (R^2 — KOEFISIEN DETERMINASI)

- **Makna Matematis R^2:** Mengukur proporsi variasi naik-turunnya data sensor yang berhasil dijelaskan oleh model (Rentang nilai: -∞ hingga 1.0).
- **R^2 Mendekati 1.0 (Misal 0.92):** Model sangat presisi; 92% dinamika fluktuasi sensor berhasil diikuti oleh kurva prediksi AI.
- **R^2 = 0.0:** Model tidak lebih pintar daripada sekadar menebak garis lurus nilai rata-rata (Mean) sepanjang waktu.
- **R^2 Negatif (< 0):** Model gagal total; garis prediksinya bahkan lebih buruk daripada menebak rata-rata kasar.

TARGETOPTIMASI ENGINEER: Model Forecasting yang baik memiliki nilai MAE dan RMSE mendekati 0.0, serta nilai R^2 mendekati 1.0 pada pengujian Testing Set.

BEDAH MATEMATIKA LANGKAH DEMI LANGKAH

Contoh Perhitungan Manual Metrik MAE, MSE, dan RMSE

Simulasi evaluasi ramalan suhu Smart Greenhouse pada 3 titik waktu pengujian (n = 3 sampel).

Waktu Uji (t)	Suhu Aktual Sensor (y_i)	Ramalan Model AI ($\hat{y}_i$)	Selisih Mutlak $\lvert y_i - \hat{y}_i \rvert$	Galat Kuadrat $(y_i - \hat{y}_i)^2$
Pukul 13:00	30.0 °C	29.0 °C	$\lvert 30.0 - 29.0 \rvert$ = 1.0 °C	$(+1.0)^2$ = 1.00
Pukul 14:00	32.0 °C	32.0 °C (Tepat!)	$\lvert 32.0 - 32.0 \rvert$ = 0.0 °C	$(0.0)^2$ = 0.00
Pukul 15:00	31.0 °C	33.0 °C (Meleset 2°C)	$\lvert 31.0 - 33.0 \rvert$ = 2.0 °C	$(-2.0)^2$ = 4.00
TOTAL & METRIK (n = 3 Sampel)	Rata-rata Aktual: $\bar{y}$ = 31.0 °C	Rata-rata Prediksi: 31.33 °C	Jumlah = 3.0 °C ➔ MAE = 3.0 / 3 = 1.00 °C	Jumlah Kuadrat = 5.00 ➔ MSE = 5.00 / 3 = 1.67 ➔ RMSE = √1.67 = 1.29 °C

MENGAPA RMSE (1.29°C) LEBIH BESAR DARI MAE (1.00°C)?: Karena pada pukul 15:00 terdapat kesalahan tebakan sebesar 2.0°C yang ketika dikuadratkan menjadi 4.00! Jika sistem Anda tidak menoleransi meleset ekstrem sesaat, gunakan RMSE sebagai acuan utama.

Mengapa Z-Score & IQR Gagal Menangkap Anomali Multivariat?

Memahami titik buta statistik satu dimensi (Univariat) pada ekosistem sensor yang saling terikat.

TITIK BUTA METODE UNIVARIAT (PEKAN 6)

- **Pemeriksaan Kolom Tunggal Terpisah:** Metode Z-Score (|Z| > 3) dan IQR (Q1 - 1.5×IQR s.d. Q3 + 1.5×IQR) hanya menguji satu kolom sensor pada satu waktu tanpa melihat kolom lainnya.
- **Mengabaikan Hukum Korelasi Fisika:** Di alam nyata, suhu udara, kelembaban relatif (RH), radiasi cahaya, dan pH tanah bergerak saling mengikat sesuai hukum termodinamika.
- **Kegagalan Deteksi Silang:** Anomali sering kali bukan berupa angka ekstrem tunggal, melainkan putusnya hubungan wajar antar-sensor!

CONTOH NYATA ANOMALI MULTIVARIAT DI LAPANGAN

- **Batas Valid IQR Sensor Suhu:** 20.0°C s.d. 35.0°C ➔ Bacaan 22.0°C dianggap 100% NORMAL oleh filter IQR Suhu.
- **Batas Valid IQR Sensor Kelembaban:** 40.0% s.d. 85.0% ➔ Bacaan 42.0% dianggap 100% NORMAL oleh filter IQR Kelembaban.
- **Mengapa Kombinasi [22.0°C & 42.0%] Berbahaya?:** Secara fisika di iklim tropis, saat udara dingin 22.0°C (malam/hujan), kelembaban udara normalnya 70%–85%! Udara dingin 22°C yang kering 42% menandakan kebocoran blower pemanas/AC yang merusak tanaman!
- **Vonis Filter Lama vs AI:** Z-Score & IQR gagal mendeteksi (lolos), sedangkan Isolation Forest langsung membunyikan alarm!

ESENSI ANOMALI MULTIDIMENSI: Sebuah titik data dapat terlihat normal pada sumbu X dan normal pada sumbu Y secara terpisah, namun menjadi pencilan mencolok saat dipetakan pada bidang koordinat (X, Y)!

Bedah Cara Kerja Algoritma Isolation Forest

Mengisolasi anomali multidimensi secara efisien menggunakan hutan pohon partisi acak (iTrees).

PRINSIP KERJA ISOLATION FOREST (LIU ET AL., 2008)

- **Paradigma Baru: Isolasi, Bukan Profil Kepadatan:** Sebagian besar algoritma lama berusaha mempelajari bentuk data normal lalu mencari yang menyimpang. Isolation Forest bekerja terbalik: langsung berusaha MENGISOLASI titik yang terpencil!
- **Mekanisme Tebasan Acak (Random Partitioning):** Algoritma membangun ratusan pohon keputusan (iTrees) dengan memilih fitur sensor secara acak (misal Suhu atau pH) lalu memotongnya pada nilai ambang acak.
- **Tanpa Butuh Label (Unsupervised):** Tidak memerlukan kolom label 'Normal/Rusak' dari manusia; bekerja langsung pada matriks sensor mentah yang sudah bersih.

PANJANG JALUR POHON: ANOMALI VS NORMAL

➔ **Titik Anomali (Outlier — Jalur Pendek):** Karena terletak jauh sendirian di luar kerumunan utama, titik anomali langsung terpisah sendirian hanya dengan 1 atau 2 kali tebasan garis pemotong! (Path length h(x) sangat pendek).

➔ **Titik Normal (Inlier — Jalur Panjang):** Karena berkumpul padat di tengah gerombolan data sehat, dibutuhkan belasan kali tebasan garis acak sampai satu titik normal terpisah sendirian.

➔ **Konvensi Output Scikit-Learn:** Fungsi model.fit_predict(df) menghasilkan angka +1 untuk Data Normal (Aman) dan angka -1 untuk Data Anomali (Bahaya!).

PARAMETER CONTAMINATION PADA SCIKIT-LEARN: Parameter IsolationForest(contamination=0.02) mengatur sensitivitas batas keputusan dengan mengasumsikan sekitar 2% dari data historis merupakan anomali.

Studi Kasus Industri: Predictive Maintenance & Smart Farming

Transformasi nilai ekonomi dari sekadar pemantauan pasif menuju pencegahan kerugian proaktif.

KASUS 1: PREDICTIVE MAINTENANCE TRAKTOR & POMPA

- **Masalah Operasional:** Roda gigi transmisi traktor otonom atau pompa irigasi utama yang patah mendadak di tengah masa panen/kemarau menimbulkan kerugian ratusan juta rupiah.
- **Akuisisi Sensor Multivariat:** Sensor getaran (akselerometer), arus motor (Ampere), dan suhu oli dipantau kontinu setiap detik.
- **Peran Machine Learning:** Model klasifikasi/anomali mengenali perubahan pola mikro-vibrasi 3 hari sebelum logam mengalami retak lelah (fatigue fracture).
- **Actionable Insight:** Notifikasi otomatis: 'Probabilitas 87% bearing pompa aus dalam 72 jam, segera jadwalkan servis sebelum rusak total.'

KASUS 2: DETEKSI MALFUNGSI FERTIGASI HIDROPONIK

- **Masalah Operasional:** Pompa pendosis nutrisi AB-Mix macet sebagian sehingga kepekatan pupuk (EC) melonjak sementara pH air turun drastis di siang hari terik.
- **Kelemahan Alarm Konvensional:** Alarm batas tunggal sering terlambat atau terlalu sering berbunyi palsu saat pergantian air baku.
- **Peran Isolation Forest:** Memantau vektor 3 dimensi [Suhu Air, pH Larutan, TDS/EC] secara serentak pada Data Pipeline Worker.
- **Actionable Insight:** Begitu kombinasi keluar dari klaster normal (Label = -1), katup penguras air otomatis terbuka menyelamatkan ribuan tanaman melon.

EVOLUSI STRATEGI PEMELIHARAAN INDUSTRI: Reactive Maintenance (Tunggu Rusak) ➔ Preventive Maintenance (Jadwal Kalender Kaku) ➔ Predictive Maintenance berbasis Machine Learning IoT (Tepat Sasaran)!

Mengapa Akurasi Model AI Menurun Setelah 6 Bulan Operasi?

Membedakan degradasi perangkat keras (Sensor Drift) dari perubahan perilaku alam (Concept Drift).

1. SENSOR DRIFT (DEGRADASI PERANGKAT KERAS)

- **Akar Penyebab Fisik:** Lempeng tembaga/elektroda kaca sensor yang tertanam di tanah atau kolam mengalami korosi kimiawi, penumpukan kerak mineral, atau lumut (bio-fouling).
- **Dampak pada Input Model (X):** Nilai bacaan sensor bergeser perlahan secara monoton dari nilai fisik sebenarnya (misal pH asli 7.0 dikirim sebagai 8.3 ke dalam model AI).
- **Solusi Perbaikan:** Bukan salah algoritma AI-nya! Solusinya adalah membersihkan probe fisik, melakukan kalibrasi ulang (re-calibration) dengan larutan standar, atau mengganti sensor.

2. CONCEPT DRIFT (PERUBAHAN DINAMIKA ALAM)

- **Akar Penyebab Lingkungan:** Perangkat keras sensor masih 100% presisi, tetapi hubungan fisis di alam telah berubah dibandingkan saat model dilatih 6 bulan lalu.
- **Contoh di Perkebunan:** Struktur kepadatan tanah memadat akibat dilewati traktor panen baru, pergantian musim kemarau ke La Nina ekstrem, atau pergantian varietas bibit tanaman.
- **Solusi Perbaikan:** Melatih ulang (Re-training) model Machine Learning di Cloud menggunakan dataset pengamatan terbaru agar bobot rumus mengikuti kondisi baru!

PROSEDUR DIAGNOSTIK ISOLASI MASALAH: Jika R^2 model anjlok dari 0.92 ke 0.45: Uji sensor fisik di laboratorium dengan larutan kalibrasi standar lebih dulu! Jika bacaan sensor di lab tetap akurat, berarti terjadi Concept Drift.

PELUNCURAN PROYEK AKHIR (RTM TUGAS BESAR — BOBOT UAS 45%)

Kick-Off Proyek Akhir: Spesifikasi Arsitektur Wajib 5 Lapis

Mulai Pekan 9, setiap kelompok (maks. 3 mahasiswa) wajib menetapkan topik studi kasus End-to-End IoT Analytics.

Lapis	Nama Komponen Wajib	Teknologi / Perangkat Lunak	Peran Fungsional dalam Pipeline Proyek Akhir
Lapis 1	Data Collector (Edge / Simulator)	Script Python Simulator / Mikrokontroler ESP32 (C++)	Membaca atau membangkitkan metrik lingkungan pertanian (suhu, kelembaban, pH, cahaya) dan mempublikasikannya via MQTT.
Lapis 2	Message Broker (Transport Hub)	Eclipse Mosquitto (MQTT) / RabbitMQ (MQTT & AMQP) / Valkey	Menerima aliran paket telemetri secara real-time dengan autentikasi keamanan dan menyangga antrean pesan.
Lapis 3	Data Pipeline Worker (Analytics Engine)	Python Daemon Worker (Pandas + Scikit-Learn + Deque)	Menangkap data dari Broker, mengeksekusi Data Cleaning (NaN/Outlier) & Smoothing secara kilat, serta menjalankan prediksi ML.
Lapis 4	Time-Series Database (Storage Engine)	InfluxDB v2 (Rekomendasi) / TimescaleDB / MongoDB TS	Menyimpan data bersih, nilai rata-rata bergerak, dan label status anomali (+1 / -1) dengan indeks waktu berkecepatan tinggi.
Lapis 5	Analytic Dashboard & Early Warning System	Grafana / Streamlit + Telegram Bot Webhook API	Menampilkan grafik real-time, indikator Gauge, serta mengirim notifikasi peringatan otomatis ke Telegram saat terdeteksi anomali.

TIMELINE PENGERJAAN PROYEK AKHIR (PEKAN 9 - 16): Pekan 9: Penetapan Kelompok & Judul Kasus | Pekan 10-11: Setup Broker & DB | Pekan 12-13: Coding Worker & ML | Pekan 14: Integrasi End-to-End | Pekan 15: Live Demo | Pekan 16: UAS.

Bahan Diskusi Kelas & Tantangan Analisis Engineer

Menguji ketajaman penalaran sebelum mempraktikkan kode Scikit-Learn pada Pekan 10.

DISKUSI #1: PERTANIAN TERBUKA VS PABRIK TERTUTUP

- **Skenario Perbandingan:** Sebuah model ML dipasang di kebun cabai terbuka (Open-Field Agriculture), sementara model kedua dipasang pada robot las di dalam gedung pabrik otomotif tertutup.
- **Pertanyaan Diskusi Kelas:** Mengapa model ML pada pertanian terbuka jauh lebih sulit mencapai akurasi stabil dan lebih sering mengalami Concept Drift dibandingkan di dalam pabrik manufaktur?
- **Petunjuk Analisis (Hint):** Tinjau dari sisi gangguan variabel tak terkendali (cuaca ekstrem, hama, mutasi biologis tanah) vs lingkungan pabrik yang terukur deterministik.

DISKUSI #2: PEMILIHAN METRIK MAE VS RMSE DI INKUBATOR

- **Skenario Kritis:** Anda membangun model Forecasting suhu untuk mesin penetas telur otomatis. Jika suhu meleset > 2.5°C selama 30 menit saja, seluruh embrio telur akan mati.
- **Pertanyaan Diskusi Kelas:** Saat menyeleksi dua kandidat model AI, apakah Anda lebih mengutamakan model dengan MAE terendah atau RMSE terendah? Mengapa?
- **Petunjuk Analisis (Hint):** Ingat bagaimana operasi penguadratan pada rumus RMSE menghukum satu kejadian galat besar secara jauh lebih berat dibandingkan rata-rata mutlak MAE!

PERSIAPAN PRAKTIKUM PEKAN 10: Pastikan lingkungan Jupyter Notebook Anda telah terpasang pustaka Scikit-Learn dan Joblib: jalankan perintah 'pip install scikit-learn joblib seaborn' sebelum pertemuan minggu depan!

Referensi & Acuan Materi Perkuliahan Pekan 9

Seluruh materi pada pertemuan ini disusun merujuk pada buku teks utama dan dokumentasi teknis berikut:

1. BUKU TEKS & PUBLIKASI AKADEMIK UTAMA

- **Minteer, A. (2017):** Analytics for the Internet of Things (IoT). Packt Publishing Ltd. (ISBN-13: 978-1787120730) — Bab 6 (Getting to Know Your Data with ML) & Bab 7 (Applying ML to IoT Data).
- **Fawcett, T., & Provost, F. (2013):** Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media. (ISBN-13: 978-1449361327) — Bab 3, Bab 4, & Bab 7.
- **Goodfellow, I., Bengio, Y., & Courville, A. (2016):** Deep Learning. MIT Press. (ISBN-13: 978-0262035613) — Bab 5 (Machine Learning Basics: Capacity, Overfitting, & Estimators).

2. DOKUMENTASI PERANGKAT LUNAK & MODUL INTERNAL

- **Scikit-learn Developers (2024):** Scikit-learn User Guide: Supervised Learning (Linear Models) & Novelty and Outlier Detection (IsolationForest). Tersedia: https://scikit-learn.org/
- **Pandas Development Team (2024):** Pandas Documentation: Time Series Shifting (.shift) & Windowing. Tersedia: https://pandas.pydata.org/docs/
- **Dokumen Repositori Mata Kuliah:** Pekan_09/Modul_Teori_Pekan_9.md, Pekan_09/Kuis_Pekan_9.md, RTM_Tugas_Besar.md, dan Referensi/Daftar_Referensi_Lengkap.md.

AGENDA SELANJUTNYA (PEKAN 10): Praktikum Terbimbing Pemodelan Machine Learning: Implementasi koding Forecasting (Lag Features) dan deteksi anomali 2D menggunakan Isolation Forest di Jupyter Notebook!